

Sentinela

Um radar semanal de risco de asteroides com CRISP-DM e LLM via API

Trabalho Final — AI Applications (MBA)

13 de julho de 2026

Versão 1.0

Resumo. Todo asteroide que passa perto da Terra é catalogado pela NASA, mas a lista bruta — dezenas de objetos por semana — não é acionável para um núcleo de divulgação científica e defesa planetária. Este trabalho aplica a metodologia CRISP-DM, dirigindo o agente Claude Code, para transformar essa lista num *digest* executivo semanal. O pipeline coleta as aproximações da semana na API pública NASA NeoWs, calcula um *baseline* físico de risco, e usa um LLM (OpenAI GPT) com **saída estruturada** (Pydantic) para produzir um resumo priorizado. O ganho de negócio é substituir a leitura manual de um feed técnico — trabalho de especialista — por um digest automático de custo marginal desprezível, que chega pronto para decisão. A avaliação é feita em três camadas: o baseline como classificador da flag oficial da NASA (AUC e F1), a concordância entre o LLM e o baseline, e uma auditoria programática da regra de ouro. Todos os números deste relatório são gerados por código que roda sobre dados reais.

Palavras-chave: CRISP-DM; LLM; saída estruturada; defesa planetária; NASA NeoWs.

1 Introdução

A defesa planetária deixou de ser ficção: agências como a NASA mantêm catálogos públicos e atualizados de objetos próximos da Terra (*Near-Earth Objects*, NEOs) e programas de monitoramento de impacto como o Sentry (NASA Jet Propulsion Laboratory 2024). O volume, porém, é alto — dezenas de aproximações por semana — e a lista bruta, técnica e sem priorização, não responde à pergunta que quem decide realmente faz: **o que merece atenção esta semana?**

Quem decide e qual decisão muda. O destinatário deste produto é o responsável por curadoria e comunicação de um planetário, museu de ciências ou veículo de jornalismo científico — e, por extensão, qualquer núcleo de monitoramento de risco de baixa probabilidade e alto impacto. A decisão semanal é concreta: *o que destacar, comunicar ou escalar* — a pauta da semana, o post nas redes, a nota à imprensa, o alerta interno. Hoje essa decisão exige que um profissional com conhecimento técnico leia manualmente o feed da NASA e traduza magnitude, diâmetro e distância em “isto importa / isto é rotina”; no cenário mais comum, ela simplesmente não é feita, e eventos relevantes passam despercebidos enquanto passagens triviais viram alarme falso.

O valor de negócio. O Sentinela troca esse trabalho especializado e recorrente por um *digest* executivo automático, de custo marginal desprezível (centavos de tokens por semana), reprodutível e auditável — horas de análise viram uma execução agendada que chega pronta para decisão. Por ser um esqueleto configurável, o mesmo pipeline atende qualquer triagem semanal de risco ou atenção — de indicadores setoriais a tickets e contratos — bastando trocar a fonte de dados e o *prompt*.

A contribuição, portanto, não é um modelo astronômico novo, e sim a **engenharia de um pipeline de IA** no espírito da disciplina: um problema de decisão claro, dados reais via API, um LLM com **saída estruturada** como camada de comunicação e julgamento, avaliação em múltiplas camadas e entrega automatizada — tudo sob a **regra de ouro** de que nenhum número é inventado.

2 Revisão da Literatura

O trabalho se apoia em três frentes. Primeiro, a metodologia **CRISP-DM** (Wirth e Hipp 2000), que organiza projetos de dados em seis fases (Negócio, Dados, Preparação, Modelagem, Avaliação e Implantação) e que usamos como mapa do projeto. Segundo, os dados e definições de **defesa planetária** da NASA/CNEOS (NASA Jet Propulsion Laboratory 2024): a API NeoWs (NASA 2024) expõe as aproximações e a flag *potentially hazardous asteroid* (PHA), definida por um critério orbital (distância mínima de interseção da órbita $< 0,05$ UA e diâmetro > 140 m) — e não pela passagem de uma semana específica, distinção central na nossa avaliação. Terceiro, o uso de **LLMs com saída estruturada** (OpenAI 2025), em que o modelo é forçado a preencher um schema fixo (aqui via Pydantic), garantindo resultados comparáveis e verificáveis — o oposto do texto livre.

3 Metodologia e Dados

Fonte. NASA NeoWs, endpoint *feed*, que retorna as aproximações num intervalo de até 7 dias. Cada objeto traz nome, magnitude absoluta, diâmetro estimado, a flag PHA e, por aproximação, data, velocidade relativa e distância de passagem (em km e em distâncias lunares).

Recorte. Uma janela de 7 dias por execução (uma semana). Mantemos apenas as colunas úteis ao risco e ao resumo, para reduzir ruído e custo de tokens.

Mapa CRISP-DM. (1) *Negócio*: priorizar atenção semanal; métrica de sucesso = o ranking de risco concordar com a flag oficial da NASA. (2) *Dados*: NeoWs. (3) *Preparação*: `coleta.py`. (4) *Modelagem*: baseline físico (`score.py`) + LLM com schema Pydantic (`resumo.py`). (5) *Avaliação*: três camadas (`avaliacao.py`). (6) *Implantação*: digest no WhatsApp agendado por GitHub Actions.

Schema de saída estruturada. O LLM é obrigado a devolver o schema abaixo — o mesmo que vira a mensagem de WhatsApp:

```
from schema import RelatorioSemanal
campos = {k: v.get("type", v.get("anyOf", "?"))
          for k, v in RelatorioSemanal.model_json_schema()["properties"].items()}
for nome, tipo in campos.items():
    print(f"- {nome}: {tipo}")
```

```
- titulo: string
- nivel_semana: string
- resumo_executivo: string
- bullets: array
- objetos_destaque: array
- numero_destaque: string
- alerta: [{'type': 'string'}, {'type': 'null'}]
```

4 Implementação

4.1 Configuração e carga dos dados

Para tornar este relatório **reprodutível** (renderiza sem chave de API e sem rede), os chunks leem um *snapshot* real de uma semana, capturado da NASA e versionado em `dados/amostra_semana.csv`. Em produção, `main.py` coleta a semana ao vivo.

```
import pandas as pd
from pathlib import Path

df = pd.read_csv(Path("dados") / "amostra_semana.csv")
print(f"Semana capturada: {len(df)} asteroides | "
      f"{int(df['perigoso_nasa'].sum())} potencialmente perigosos (NASA).")
```

Semana capturada: 32 asteroides | 4 potencialmente perigosos (NASA).

4.2 Coleta e preparação (NeoWs → DataFrame)

O módulo `coleta.py` faz a chamada com *retry* e *backoff* exponencial, achata o JSON e devolve um DataFrame enxuto. Trecho essencial:

Tabela 1: Top 8 asteroides da semana pelo baseline de risco (dados reais).

nome	di diametro_m	velocidade_kms	distancia_lunar	score_risco	nivel	perigoso_nasa
452639 (2005 UY6	1012.8	31.07	69.9	100	Crítico	False
663491 (2007 RT9	663	22.03	154	80.8	Crítico	False
2007 RT9	657	22.03	154	80.7	Crítico	False
250680 (2005 QC5	510	15.2	79.2	79.7	Crítico	True
2013 AS27	227.8	17.91	33	77.9	Crítico	True
2016 NG15	323.3	20.08	74.9	75.9	Crítico	True
2008 MG1	460.8	18.8	165.4	72.4	Alto	False
2012 XM145	357.7	16.88	144.3	68.6	Alto	False

```
def coletar_semana(fim=None):
    fim = fim or date.today()
    inicio = fim - timedelta(days=6) # janela de 7 dias (limite da API)
    params = {"start_date": inicio.isoformat(), "end_date": fim.isoformat(),
              "api_key": os.getenv("NASA_API_KEY", "DEMO_KEY")}
    resp = _sessao_com_retry().get(API_URL, params=params, timeout=30)
    resp.raise_for_status()
    # ... achata near_earth_objects e ordena pela menor distância
```

4.3 Modelagem — baseline físico

O baseline (`score.py`) é uma heurística transparente: energia cinética como *proxy* (massa $\propto$ diâmetro³, energia $\propto$ massa $\times$ velocidade²) ponderada pela proximidade, normalizada para 0–100 em escala log dentro da semana.

4.4 Modelagem — LLM com saída estruturada

`resumo.py` força o GPT a preencher o schema `RelatorioSemanal` via *structured outputs* (`response_format`, `temperature=0`). O system prompt fixa a persona e a regra de ouro. Abaixo, o resumo estruturado gerado para esta semana:

```
import json
from schema import RelatorioSemanal

meta = json.loads(Path("dados/relatorio_meta.json").read_text(encoding="utf-8"))
rel = RelatorioSemanal.model_validate_json(
    Path("dados/relatorio_exemplo.json").read_text(encoding="utf-8"))

print(f"[proveniência: {meta['gerado_por']}] \n")
print(f"Titulo: {rel.titulo}")
print(f"Nível : {rel.nivel_semana}")
print(f"Resumo: {rel.resumo_executivo}")
print("Destaques:")
for o in rel.objetos_destaque:
    print(f" - {o.nome}: score {o.score_risco:.0f}, {o.distancia_lunar:.0f} dist. lunares")
```

Tabela 2: Baseline como classificador da flag PHA, por limiar de decisão.

limiar	TP	FP	FN	TN	precisão	recall	F1	acurácia
25	4	21	0	7	0.16	1	0.276	0.344
40	4	11	0	17	0.267	1	0.421	0.656
50	4	10	0	18	0.286	1	0.444	0.688
60	3	7	1	21	0.3	0.75	0.429	0.75
75	3	3	1	25	0.5	0.75	0.6	0.875

AUC (independe do limiar): 0.857

[proveniência: OpenAI GPT (gpt-4o-mini) via structured outputs]

Título: Resumo Semanal de Asteroides Próximos à Terra

Nível : Atenção

Resumo: Nesta semana, monitoramos 32 asteroides próximos à Terra, dos quais 4 são considerados potencialmente perigosos.

Destaques:

- 250680 (2005 QC5: score 80, 79 dist. lunares
- 2013 AS27: score 78, 33 dist. lunares
- 2016 NG15: score 76, 75 dist. lunares

5 Resultados

5.1 Avaliação em três camadas

Camada 1 — baseline vs. a verdade oficial da NASA. Tratamos o `score_risco` como um classificador da flag PHA e varremos o limiar de decisão:

A Tabela 2 mostra o *trade-off* central: com limiar baixo o baseline captura **todos** os objetos perigosos (recall alto), ao custo de superalertar (precisão baixa). O **AUC**, independente de limiar, resume a capacidade de ordenação.




Figura 1: Distribuição do score de risco por classe oficial da NASA (PHA vs. não-PHA).

Camadas 2 e 3 — concordância LLM×baseline e auditoria da regra de ouro.

Destaques do LLM: rank médio 5.0 de 32 | no topo do baseline: 100% | perigosos (NASA): 100%
 Regra de ouro: 9 números conferidos | OK=True | violações=0

6 Avaliação crítica e limitações

- **O baseline e a flag PHA medem coisas diferentes.** A flag da NASA é **orbital** (MOID e tamanho, válida para todas as passagens futuras); nosso score é sobre a **passagem da semana**. Por isso um objeto grande que passa longe pode pontuar alto sem ser PHA — não é um erro do modelo, é uma diferença de definição. O valor do baseline é como **triador de atenção semanal** (recall e AUC altos), não como réplica do critério orbital.
- **Diâmetro é estimado** a partir da magnitude (faixa min–max); usamos o ponto médio.
- **O LLM não computa risco** — ele comunica os números do baseline. A regra de ouro é garantida por schema fixo e auditada programaticamente (Camada 3).
- **O LLM afia o foco.** Em vez de copiar o topo do score físico bruto (dominado por objetos grandes que passam longe), o modelo priorizou os objetos que são, ao mesmo tempo, de alto score e **oficialmente perigosos (PHA)** — todos no topo do baseline e 100% marcados pela NASA (Camada 2). É a camada de comunicação agregando julgamento de negócio, sem violar a regra de ouro.
- **Amostra de uma semana** para reprodutibilidade do PDF; o pipeline roda continuamente.

7 Próximos Passos

Incorporar a escala de Torino e dados do Sentry (probabilidade de impacto) como *features*; calibrar o score contra múltiplas semanas; e testar mais de um provedor de LLM comparando custo e fidelidade da saída estruturada.

8 Conclusão

O Sentinela mostra que o valor não está no “chat”, e sim no **pipeline**: um problema de decisão real — *o que priorizar e comunicar esta semana* — vira um produto reprodutível e automatizado que substitui horas de análise especializada por um digest de custo marginal desprezível, com dados reais, LLM de saída estruturada como camada de comunicação e uma avaliação honesta que separa o que o baseline faz bem (triar) do que ele não se propõe a fazer (replicar o critério orbital da NASA). O método — CRISP-DM dirigindo o agente — e o esqueleto configurável são o que se transferem para qualquer outra triagem de risco ou atenção: basta trocar a fonte e o *prompt*.

9 Referências

NASA. 2024. *NeoWs — Near Earth Object Web Service*. <https://api.nasa.gov/>.

NASA Jet Propulsion Laboratory. 2024. *Center for Near-Earth Object Studies (CNEOS)*. <https://cneos.jpl.nasa.gov/>.

OpenAI. 2025. *Structured Outputs with Large Language Models*. <https://platform.openai.com/docs/guides/structured-outputs>.

Wirth, Rüdiger, e Jochen Hipp. 2000. “CRISP-DM: Towards a Standard Process Model for Data Mining”. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.